



Rheinische
Hochschule
Köln

Fachbereich Ingenieurwesen

Studiengang Technical Management (M.Eng.)

Angewandte Machine Learning

Mietpreisvorhersage in Deutschland mittels
maschinellem Lernen

Vorgelegt von

Abdullah Sarwar

Matrikelnr. 132261051

und

Serkan Dülger

Matrikelnr. 132251079

Prof. Dr.-Ing. Bugra Turan

Inhaltsverzeichnis

1.	Einleitung	1
1.1	Motivation und Zielsetzung	1
1.2	Abgrenzung und Vorgehen	2
2.	Datensatz und Datenquelle	3
2.1	Zielvariable	3
2.2	Umfang und Merkmale	3
2.3	Explorative Datenanalyse	4
3.	Datenvorverarbeitung	5
3.3	Kodierung kategorialer Merkmale	7
3.4	Feature Engineering	7
4.	Verwendete Modelle	8
4.1	Ridge Regression	8
4.2	Gradient Boosting Regressor	9
4.3	Neuronales Netz	9
5.	Trainingsprozess	10
5.1	Datenaufteilung	10
5.2	Begründung der gewählten Trainingsstrategie	10
6.	Evaluation der Modelle	11
6.1	Bewertungsmetriken (MAE, RMSE, R^2 , MAPE)	11
6.2	Ergebnisse im Vergleich	11
6.3	Interpretation der Ergebnisgrafiken	13
6.4	Overfitting-Analyse	14
6.5	Fehleranalyse	14
7.	Erklärbarkeit und Interpretierbarkeit	15
7.1	Motivation und Methodenwahl	15
7.2	Globale Erklärbarkeit: Merkmalswichtigkeit des Gradient-Boosting-Modells	15
7.3	Interpretierbarkeit der linearen Baseline	16
7.4	Grenzen der Erklärbarkeit und Ausblick	16
8.	Räumliche Analyse	17
8.1	Bedeutung der räumlichen Merkmale	17
8.2	Interaktive Karten (Leaflet / OpenStreetMap)	18

9.	Unsicherheitsanalyse	19
9.1	Motivation	19
9.2	Methodik	19
9.3	Ergebnisse	20
10.	Kritische Diskussion	21
10.1	Begrenzte Datenmenge und zeitliche Abdeckung	21
10.2	Vereinfachte räumliche Darstellung	21
10.3	Fehlende externe Einflussgrößen	21
10.4	Datenqualität	22
10.5	Softwaretechnische Aspekte	22
11.	Verbesserungsmöglichkeiten und Ausblick	23
12.	Fazit	24

1. Einleitung

Die Vorhersage von Mietpreisen ist ein praxisrelevantes Anwendungsgebiet des maschinellen Lernens: Für Mietinteressenten, Vermieter und Immobilienportale ist eine genaue Schätzung der zu erwartenden Miete wertvoll. Der Mietpreis wird dabei von vielen, teils nichtlinear zusammenwirkenden Faktoren bestimmt – etwa Wohnfläche, Zimmerzahl, Baujahr, Ausstattung und vor allem der Lage. Die vorliegende Arbeit entwickelt auf Basis realer Wohnungsanzeigen ein System zur Vorhersage der monatlichen Nettokaltmiete und legt dabei Wert nicht nur auf die Vorhersagegüte, sondern auch auf die Nachvollziehbarkeit der Vorhersagen.

1.1 Motivation und Zielsetzung

Klassische Schätzverfahren wie der Vergleich mit ähnlichen Objekten stoßen an Grenzen, sobald viele Merkmale gleichzeitig und nichtlinear auf den Preis wirken; maschinelle Lernverfahren erfassen solche Zusammenhänge datengetrieben. In der Praxis genügt eine reine Punktvorhersage jedoch oft nicht – man möchte auch verstehen, warum ein Preis zustande kommt. Gerade leistungsfähige Modelle wie Gradient Boosting oder neuronale Netze verhalten sich dabei als „Black Box“. Ziel der Arbeit ist daher die Entwicklung und vergleichende Bewertung dreier Modellklassen unterschiedlicher Komplexität – einer Ridge Regression als interpretierbare Baseline, eines Gradient-Boosting-Regressors und eines neuronalen Netzes – sowie die transparente Darstellung der wichtigsten Preistreiber. Ergänzt wird dies durch eine Analyse der Modellunsicherheit und eine räumliche Untersuchung regionaler Preisunterschiede. Die zentrale Fragestellung lautet: „Wie genau lässt sich die monatliche Nettokaltmiete einer Wohnung anhand verfügbarer Wohnungsmerkmale vorhersagen?“ Da die Zielgröße ein kontinuierlicher Zahlenwert ist, handelt es sich um ein Regressionsproblem.

1.2 Abgrenzung und Vorgehen

Die Untersuchung beschränkt sich auf öffentlich inserierte Wohnungsangebote eines einzelnen Immobilienportals; vorhergesagt wird ausschließlich die Nettokaltmiete. Da es sich um Angebotsmieten handelt, können die Daten vom realen Mietniveau abweichen. Die Modelle identifizieren statistische Zusammenhänge, treffen jedoch keine kausalen Aussagen, und aufgrund der begrenzten zeitlichen Abdeckung wird keine echte Trendprognose angestrebt. Methodisch orientiert sich die Arbeit am CRISP-DM-Prozess: Auf Datenverständnis und Vorverarbeitung (fehlende Werte, Ausreißer, Kodierung, Feature Engineering) folgen Training und Bewertung der Modelle (MAE, RMSE, R^2 , MAPE), anschließend deren Interpretation sowie die räumliche und unsicherheitsbezogene Analyse. Die Umsetzung erfolgt in Python als modular aufgebaute Pipeline.

Aus der Aufgabenstellung ergeben sich mehrere zu erwartende Herausforderungen. Die Zielvariable ist stark rechtsschief verteilt und enthält hochpreisige Ausreißer, die das Training verzerren können; zudem nimmt die Streuung der Mieten mit steigendem Preis zu (Heteroskedastizität), was gleichmäßig genaue Vorhersagen über alle Preissegmente erschwert. Die kategorialen und insbesondere die regionalen Merkmale (Bundesland, Landkreis, Postleitzahl) weisen viele Ausprägungen auf und erfordern eine geeignete Kodierung, die die Modellgüte spürbar beeinflusst. Die zeitliche Abdeckung des Datensatzes ist begrenzt, sodass eine echte zeitliche Generalisierung nur eingeschränkt überprüfbar ist. Schließlich verhalten sich die leistungsfähigeren Modelle als „Black Box“, weshalb ihre Nachvollziehbarkeit eine eigene Herausforderung darstellt.

2. Datensatz und Datenquelle

Als Datengrundlage dient der öffentlich auf Kaggle verfügbare Datensatz „Apartment rental offers in Germany“. Die Daten wurden von ImmoScout24, der größten Immobilienplattform Deutschlands, gescraped und enthalten ausschließlich Wohnungsangebote; sie umfassen damit nur die auf der Plattform veröffentlichten Informationen. Die Erhebung erfolgte in mehreren Scraping-Durchläufen mit hinterlegtem Erhebungszeitpunkt; die Inserate reichen bis Februar 2020 und stellen somit eine Momentaufnahme des deutschen Mietmarkts in diesem Zeitraum dar. Der Datensatz ist öffentlich auf Kaggle verfügbar (<https://www.kaggle.com/datasets/corrieaar/apartment-rental-offers-in-germany>) und wird unter der dort angegebenen Lizenz Data files © Original Authors bereitgestellt. Aufgrund ihrer Größe ist die Originaldatei nicht Teil des Repositorys.

2.1 Zielvariable

Zielvariable ist die monatliche Nettokaltmiete (baseRent), also die Grundmiete ohne Neben- und Heizkosten. Sie wurde bewusst gegenüber der Warmmiete gewählt, da sie unabhängig von uneinheitlich erfassten Nebenkosten den am besten vergleichbaren Preisbestandteil bildet. Ihre Verteilung ist deutlich rechtsschief: Die mittlere Nettokaltmiete liegt im Trainingsdatensatz bei rund 607 €, der Median mit rund 470 € erkennbar darunter; nach der Ausreißer Bereinigung reicht der Wertebereich bis etwa 2.500 €. Diese Schiefe motiviert die spätere Ausreißer Behandlung und ist bei der Wahl der Fehlermaße zu berücksichtigen.

2.2 Umfang und Merkmale

Aus dem deutlich umfangreicheren Gesamtdatensatz (rund 268.000 Inserate, ca. 272 MB) wurden aus Gründen der Laufzeit und Reproduzierbarkeit die ersten 50.000 Inserate eingelesen. Nach Entfernung fehlerhafter Datensätze und der Ausreißer Bereinigung verblieben 49.000 Inserate. Jedes Objekt wird durch 21 ausgewählte Merkmale beschrieben – darunter Wohnfläche (livingSpace), Zimmerzahl (noRooms), Baujahr (yearConstructed), Objektzustand (condition), Heizungsart (heatingType), Wohnungstyp (typeOfFlat), Bundesland (regio1) sowie Ausstattungs- und Inseratsmerkmale wie Balkon, Einbauküche, Aufzug und Bildanzahl. Zusammen mit den in Abschnitt 3.4 erzeugten Zeitmerkmalen (Jahr, Monat, Quartal, Jahreszeit) ergeben sich die 25 Merkmale, auf denen die Modelle trainiert werden. Die Merkmale umfassen metrische Größen (z. B. Wohnfläche, Zimmerzahl, Baujahr, Nebenkosten), binäre Ausstattungsmerkmale (z. B. Balkon, Einbauküche, Aufzug) sowie kategoriale Merkmale (z. B. Objektzustand, Heizungsart, Wohnungstyp, Bundesland).

Datensatz	Anzahl	Anteil
Training	34.464	≈ 70 %
Validierung	7.268	≈ 15 %
Test	7.268	≈ 15 %

Tabelle 1 Aufteilung der Daten in Trainings-, Validierungs- und Testdatensatz.

Die Aufteilung erfolgt zeitlich, sodass der Testdatensatz aus dem aktuell verfügbaren Zeitraum (Februar 2020) stammt; die Begründung folgt in Kapitel 5. Da die ersten 50.000 Inserate statt einer Zufallsstichprobe eingelesen wurden, ist eine Verzerrung bei vorsortiertem Ausgangsdatsatz möglich (vgl. Kapitel 10).

2.3 Explorative Datenanalyse

Vor der Modellierung wurde der Datensatz explorativ untersucht (Abbildung 1). Histogramm und Boxplot der Nettokaltmiete bestätigen die rechtsschiefe Verteilung mit zahlreichen hochpreisigen Ausreißern; das Streudiagramm von Wohnfläche und Miete zeigt einen positiven, näherungsweise linearen Zusammenhang mit zunehmender Streuung (Heteroskedastizität). In der Korrelationsanalyse ist die Wohnfläche der stärkste Einflussfaktor ($\approx 0,60$), gefolgt von Nebenkosten (serviceCharge, $\approx 0,52$), einem Preistrend-Merkmal (pricetrend, $\approx 0,47$), der Bildanzahl (picturecount, $\approx 0,42$) und der Zimmerzahl ($\approx 0,40$); Ausstattungsmerkmale korrelieren schwächer ($\approx 0,2$ – $0,28$). Auffällig ist, dass mit serviceCharge, pricetrend und picturecount mehrere der stärksten Korrelate keine physischen Wohnungseigenschaften, sondern Kosten- bzw. Inseratsmerkmale sind; ob die Modelle tatsächlich auf sie zurückgreifen, wird in Kapitel 7 anhand der Merkmalswichtigkeit geprüft. Besonders deutlich sind die regionalen Unterschiede: Die durchschnittliche Nettokaltmiete reicht von rund 376 € in der günstigsten bis zu rund 1.208 € in der teuersten Region – eine Spanne von etwa 832 € –, was die große Bedeutung der Lage unterstreicht (vertieft in Kapitel 8).

3. Datenvorverarbeitung

Die Qualität der Modellergebnisse hängt unmittelbar von der Datenqualität ab. Da die Roh-Inserate fehlende Werte, fehlerhafte Einträge und Ausreißer enthalten und kategoriale Merkmale nicht direkt verarbeitet werden können, war eine mehrstufige Vorverarbeitung erforderlich, die aus den 50.000 eingelesenen Inseraten die 49.000 für Training und Evaluation genutzten Beobachtungen erzeugte.

3.1 Behandlung fehlender Werte

Zunächst wurden Datensätze ohne Zielvariable (baseRent) oder ohne gültige Datumsangabe entfernt. Für die verbleibenden Datensätze wurden fehlende numerische Werte mittels Median-Imputation ersetzt, da der Median gegenüber Ausreißern robuster ist als der Mittelwert. Fehlende kategoriale Werte wurden nicht separat imputiert, sondern durch die Umwandlung in Zeichenketten als eigene Kategorie behandelt und anschließend kodiert. So konnte ein Großteil der Daten erhalten bleiben, ohne vollständige Datensätze zu verwerfen.

3.2 Behandlung von Ausreißern

Die rechtsschiefe Verteilung der Nettokaltmieten enthält einzelne sehr hohe Werte, die das Training verzerren und fehlerbasierte Metriken überproportional beeinflussen können. Zur Reduzierung dieses Effekts wurde eine quantilbasierte Bereinigung durchgeführt: Datensätze mit einer Nettokaltmiete unterhalb des 1 %- oder oberhalb des 99 %-Quantils wurden entfernt, ausschließlich auf Basis der Zielvariable. Dadurch entfielen 1.000 der 50.000 Datensätze, sodass 49.000 verblieben. Der Vorteil dieses Vorgehens liegt darin, dass keine festen Schwellenwerte nötig sind, sondern sich die Bereinigung an der tatsächlichen Verteilung orientiert und die Modelle auf einem repräsentativen Ausschnitt trainiert werden.



Abbildung 1 Explorative Datenanalyse – Verteilung der Nettokaltmiete, Korrelationen und regionale Unterschiede.

3.3 Kodierung kategorialer Merkmale

Da die Modelle nur numerische Eingaben verarbeiten, wurden kategoriale Merkmale per Label-Encoding in ganze Zahlen überführt; so wurde etwa das Bundesland (regio1) auf die Codes 0 bis 15 abgebildet, analog Objektzustand, Heizungsart und Wohnungstyp. Binäre Ausstattungsmerkmale wie Balkon, Einbauküche, Aufzug und Neubau wurden als 0/1-Indikatoren dargestellt. Zu beachten ist, dass die vergebenen Zahlen eine künstliche Rangordnung suggerieren, die bei nominalen Merkmalen nicht besteht: Baumbasierte Verfahren sind hiergegen robust, lineare Modelle wie die Ridge Regression interpretieren den Zahlenwert hingegen als Größenordnung (vgl. Kapitel 10). Ein Nebeneffekt ist, dass Regionen in den Grafiken zunächst als Zahlencodes erscheinen; für die Karten (Kapitel 8) werden sie über die inverse Transformation wieder auf die Bundeslandnamen zurückgeführt.

3.4 Feature Engineering

Ergänzend wurden aus der Datumsinformation (date) vier zeitliche Merkmale abgeleitet – Jahr (year), Monat (month), Quartal (quarter) und Jahreszeit (season) –, um zeitliche und saisonale Einflüsse abzubilden. Weitere Schritte wie die Ableitung des Gebäudealters, Baualtersklassen, Interaktionsmerkmale oder Log-Transformationen wurden nicht umgesetzt; der Fokus lag auf den vorhandenen Wohnungs-, Ausstattungs- und Regionalmerkmalen sowie den neuen Zeitmerkmalen. Eine Standardisierung der Merkmale (für Ridge und das neuronale Netz erforderlich) wird in Kapitel 5 beschrieben. Nach der Feature-Erzeugung standen 25 Eingangsmerkmale zur Verfügung.

4. Verwendete Modelle

Zur Vorhersage der Nettokaltmiete werden drei Modellklassen bewusst unterschiedlicher Komplexität eingesetzt und verglichen – von einem einfachen, vollständig interpretierbaren linearen Verfahren bis zu flexibleren, schwerer durchschaubaren nichtlinearen Modellen. Den Ausgangspunkt bildet die Ridge Regression als Baseline, darauf folgen ein Gradient-Boosting-Regressor und ein neuronales Netz, die nichtlineare Zusammenhänge und Wechselwirkungen erfassen können. Alle drei nutzen denselben Satz von 25 Merkmalen und dieselbe Datengrundlage (Kapitel 5) und sind damit unmittelbar vergleichbar. Leitend ist der Zielkonflikt zwischen Vorhersagegüte und Interpretierbarkeit: Das lineare Modell liefert direkt nachvollziehbare Koeffizienten, während die stärkeren Verfahren die in Kapitel 7 behandelten Methoden der Erklärbarkeit erfordern.

4.1 Ridge Regression

Die Ridge Regression erweitert die lineare Regression um einen L2-Strafterm, der die Summe der quadrierten Koeffizienten bestraft und so große Koeffizienten dämpft; das verringert die Anfälligkeit gegenüber Multikollinearität und wirkt einer Überanpassung entgegen. Die Regularisierungsstärke wird über den Parameter α gesteuert (hier $\alpha = 1,0$). Da der Strafterm an der Größenordnung der Koeffizienten ansetzt, wurden die Merkmale zuvor mit dem StandardScaler z-standardisiert. Der Vorzug des Verfahrens liegt in seiner unmittelbaren Interpretierbarkeit, da Vorzeichen und Betrag der Koeffizienten Richtung und Stärke des Einflusses angeben. Zugleich kann es nur lineare, additive Zusammenhänge abbilden; nichtlineare Effekte und Wechselwirkungen bleiben ihm verborgen. Eine weitere Einschränkung ist die in Abschnitt 3.3 beschriebene Label-Kodierung, deren künstliche Rangordnung gerade ein lineares Modell fehlinterpretiert (vgl. Kapitel 10).

4.2 Gradient Boosting Regressor

Der Gradient-Boosting-Regressor kombiniert viele einfache Regressionsbäume zu einem Gesamtmodell. Die Bäume werden sequentiell trainiert, wobei jeder neue Baum die verbleibenden Fehler (Residuen) der bisherigen Summe verringert – formal ein Gradientenabstieg im Funktionenraum. Dadurch erfasst das Verfahren nichtlineare Zusammenhänge und Wechselwirkungen, ohne dass diese explizit modelliert werden müssen. Konfiguriert wurde es mit 200 Bäumen ($n_estimators = 200$), maximaler Tiefe 6 ($max_depth = 6$) und einer Lernrate von 0,1. Zur Erhöhung der Robustheit lernt jeder Baum auf einer zufälligen Teilstichprobe von 80 % der Daten ($subsample = 0,8$, stochastisches Gradient Boosting); zusätzlich bricht das Training ab, wenn sich der Fehler auf 10 % zurückgehaltener Daten über zehn Iterationen nicht verbessert ($n_iter_no_change = 10$, $validation_fraction = 0,1$). Da baumbasierte Verfahren skaleninvariant sind, wurde das Modell – anders als Ridge und das neuronale Netz – auf den nicht standardisierten Merkmalen trainiert. Seiner hohen Güte steht eine geringere unmittelbare Interpretierbarkeit gegenüber, weshalb es in Kapitel 7 über die Merkmalswichtigkeit untersucht wird.

4.3 Neuronales Netz

Als komplexestes Modell dient ein vorwärtsgerichtetes, vollständig verbundenes Mehrschicht-Perzeptron (MLP), das als universeller Funktionsapproximator sehr komplexe nichtlineare Zusammenhänge abbilden kann. Die Architektur besteht aus einer Eingabeschicht für die 25 Merkmale, drei verborgenen Schichten mit 256, 128 und 64 Neuronen (ReLU-Aktivierung) sowie einer linearen Ausgabeschicht mit einem Neuron. Gegen Überanpassung wirken zwei Mechanismen: ein Dropout nach jeder verborgenen Schicht (30 %, 30 %, 20 %) und eine L2-Regularisierung der Gewichte (Faktor 0,001). Insgesamt verfügt das Netz über 47.873 trainierbare Parameter. Trainiert wurde mit dem Adam-Optimierer (Lernrate 0,001) über 100 Epochen bei Batch-Größe 32, mit dem mittleren quadratischen Fehler (MSE) als Verlustfunktion und dem MAE als überwachter Metrik; wie die Ridge Regression wurde es auf den standardisierten Merkmalen trainiert. Als ausgeprägtestes „Black-Box“-Modell werden seine Vorhersagen in Kapitel 7 ebenfalls über die Erklärbarkeit beleuchtet.

5. Trainingsprozess

Dieses Kapitel beschreibt den Trainingsprozess, insbesondere die Aufteilung der Daten in Trainings-, Validierungs- und Testdaten sowie die Begründung der gewählten zeitlichen Strategie – beides entscheidend für eine realistische, unverzerrte Bewertung.

5.1 Datenaufteilung

Die 49.000 Beobachtungen wurden in drei disjunkte Teilmengen geteilt: Trainingsdaten zum Schätzen der Parameter, Validierungsdaten zur Beobachtung des Generalisierungsverhaltens und Testdaten zur abschließenden Bewertung. Die Aufteilung erfolgt zeitlich: Trainingsdaten sind die Inserate von 2018 und 2019, die Inserate von 2020 werden je zur Hälfte auf Validierung und Test verteilt. Daraus ergibt sich die Aufteilung von 34.464 / 7.268 / 7.268 ($\approx 70/15/15\%$). Ein Rückfallmechanismus sorgt für Robustheit: Liegen für 2020 zu wenige Datensätze vor, wird ersatzweise geschichtet nach Quartal zufällig aufgeteilt. Die anschließende Standardisierung (StandardScaler) wird ausschließlich auf den Trainingsdaten angepasst und dann auf Validierung und Test angewendet, um Data Leakage zu vermeiden; sie betrifft Ridge und das neuronale Netz, während der Gradient-Boosting-Regressor auf den nicht standardisierten Merkmalen trainiert wird.

5.2 Begründung der gewählten Trainingsstrategie

Die zeitliche statt zufällige Aufteilung folgt dem Anwendungszweck: In der Praxis sind aus vergangenen Inseraten die Mieten künftiger Angebote zu schätzen. Das Training auf älteren (2018–2019) und die Bewertung auf jüngeren Daten (2020) bildet dieses Szenario nach und ist aussagekräftiger als eine zufällige Aufteilung, bei der die zeitliche Nähe die Güte zu optimistisch erscheinen ließe; zugleich wird zeitlicher Informationsabfluss vermieden. Einschränkend bleibt die schmale zeitliche Abdeckung: Da die 2020er-Inserate im Wesentlichen aus einer einzelnen Erhebung (Februar 2020) stammen, sind keine belastbaren Aussagen über echte zeitliche Generalisierung oder langfristige Trends möglich (vgl. Kapitel 10).

6. Evaluation der Modelle

Dieses Kapitel bewertet die drei Modelle anhand mehrerer Fehlermaße, vergleicht ihre Güte auf dem Testdatensatz, interpretiert die Ergebnisgrafiken und untersucht das Generalisierungsverhalten.

6.1 Bewertungsmetriken (MAE, RMSE, R^2 , MAPE)

Herangezogen werden vier Fehlermaße: Der mittlere absolute Fehler (MAE) gibt die durchschnittliche Abweichung in Euro an und ist unmittelbar interpretierbar. Der RMSE misst die Abweichung ebenfalls in Euro, gewichtet große Fehler durch die Quadrierung aber stärker; ein deutlich über dem MAE liegender RMSE deutet auf einzelne große Fehlprognosen hin. Das Bestimmtheitsmaß R^2 gibt den Anteil erklärter Varianz an (0 bis 1, höher ist besser). Der mittlere absolute prozentuale Fehler (MAPE) setzt den Fehler ins Verhältnis zur tatsächlichen Miete und erlaubt eine preisunabhängige, relative Einordnung in Prozent.

6.2 Ergebnisse im Vergleich

Modell	Datensatz	MAE (€)	RMSE (€)	R^2	MAPE
Ridge Regression	Training	141,38	206,11	0,7215	≈ 26 %
	Validierung	142,6	216,44	0,6993	≈ 25 %
	Test	145,04	217,93	0,7092	≈ 24 %
Gradient Boosting	Training	68,07	100,53	0,9337	≈ 12 %
	Validierung	90,32	142,77	0,8692	≈ 14 %
	Test	89,74	143,92	0,8732	≈ 14 %
Neuronales Netz	Training	105,23	164,7	0,8222	≈ 17 %
	Validierung	121,95	185,18	0,7799	≈ 21 %
	Test	123,76	191,09	0,7764	≈ 20 %

Tabelle 2 Bewertungsmetriken der drei Modelle auf Trainings-, Validierungs- und Testdaten.

Auf dem Testdatensatz zeigt sich eine klare Rangfolge: Der Gradient-Boosting-Regressor erreicht mit einem MAE von rund 90 € und $R^2 = 0,873$ die mit Abstand beste Güte und erklärt damit etwa 87 % der Varianz. Das neuronale Netz folgt (MAE ≈ 124 €, $R^2 = 0,776$), die Ridge Regression bleibt zurück (MAE ≈ 145 €, $R^2 = 0,709$). Dies entspricht den Erwartungen: Das rein lineare Modell kann die nichtlinearen Zusammenhänge des Mietmarkts nur eingeschränkt abbilden, während Gradient Boosting sie gut erfasst und zudem robust gegenüber der Label-Kodierung ist. Dass das neuronale Netz dahinter zurückbleibt, ist für tabellarische Daten typisch: Baumverfahren sind bei gemischt numerisch-kategorialen Merkmalen meist überlegen, zumal begrenzte Datenmenge und Label-Kodierung das Netz benachteiligen. Der bei allen Modellen deutlich über dem MAE liegende RMSE weist zudem auf einzelne große Fehlprognosen bei hochpreisigen Objekten hin.

6.3 Interpretation der Ergebnisgrafiken

Abbildung 2 fasst die Bewertung grafisch zusammen. Die obere Reihe stellt vorhergesagte gegen tatsächliche Mieten dar: Je enger die Punktwolke an der Diagonale (perfekte Vorhersage) liegt, desto genauer das Modell. Beim Gradient-Boosting-Regressor liegen die Punkte am dichtesten an der Geraden, bei der Ridge Regression streuen sie am stärksten; mit steigender Miete nimmt die Streuung zu, und alle Modelle unterschätzen sehr hochpreisige Objekte tendenziell. Die untere Reihe ergänzt drei Diagnosen: Die Residuen-Violinplots zeigen für alle Modelle eine annähernd symmetrische, um null zentrierte Fehlerverteilung (am schmalsten beim Gradient Boosting), das Balkendiagramm von MAE und RMSE veranschaulicht die Rangfolge und die Trainingshistorie des neuronalen Netzes zeigt dessen Konvergenz über die Epochen.




Abbildung 2 Modellbewertung – Vorhersage vs. Wirklichkeit, Residuen, MAE/RMSE-Vergleich und NN-Trainingsverlauf.

6.4 Overfitting-Analyse

Zur Beurteilung der Generalisierung werden die Gütemaße über die drei Datensätze verglichen. Die Ridge Regression zeigt mit nahezu identischen Werten auf Trainings- und Testdaten (R^2 0,722 vs. 0,709) keine Überanpassung, sondern eher eine Unteranpassung – das Modell ist zu einfach. Der Gradient-Boosting-Regressor fällt von Training (R^2 0,934, MAE 68 €) auf Test (R^2 0,873, MAE 90 €) zurück, was eine Moderate, durch Baumtiefe, Subsampling und Abbruchkriterium begrenzte Überanpassung anzeigt. Das neuronale Netz verhält sich ähnlich (R^2 0,822 vs. 0,776), begrenzt durch Dropout und L2-Regularisierung. Insgesamt generalisiert der Gradient-Boosting-Regressor trotz des etwas größeren Trainings-Test-Abstands am besten; die geringe Differenz zwischen Validierung und Test bestätigt zudem, dass die Validierungsdaten ein verlässlicher Indikator waren.

6.5 Fehleranalyse

Eine genauere Betrachtung der Fehler des besten Modells (Gradient-Boosting-Regressor) zeigt ein systematisches Muster: Die größten Abweichungen treten bei hochpreisigen Objekten auf, die das Modell tendenziell unterschätzt – erkennbar am deutlich über dem MAE liegenden RMSE sowie an der mit steigender Miete zunehmenden Streuung in Abbildung 2. Ursächlich sind die geringe Zahl sehr teurer Inserate (rechtsschiefe Verteilung) sowie nicht erfasste Einflussgrößen wie Mikrolage oder Ausstattungsdetails, die gerade im hochpreisigen Segment stark variieren. Im mittleren Preissegment, in dem die meisten Daten liegen, sind die Vorhersagen dagegen am genauesten. Der mittlere Residualwert von rund 22 € zeigt zudem, dass keine durchgehende systematische Über- oder Unterschätzung über alle Objekte hinweg vorliegt, sondern die Fehler vor allem an den Rändern des Preisspektrums entstehen.

7. Erklärbarkeit und Interpretierbarkeit

Leistungsfähige Modelle wie der Gradient-Boosting-Regressor oder das neuronale Netz erzielen eine hohe Güte, ihre Entscheidungslogik bleibt von außen jedoch verborgen. Für die Akzeptanz einer Mietpreisschätzung ist es aber wichtig zu verstehen, welche Merkmale eine Vorhersage in welche Richtung treiben. Dieses Kapitel untersucht daher, auf welche Merkmale sich die Modelle stützen. Im Vordergrund steht die Merkmalswichtigkeit des leistungsstärksten Modells; ergänzend werden die Interpretierbarkeit der linearen Baseline und die Grenzen des Ansatzes betrachtet.

7.1 Motivation und Methodenwahl

Interpretierbarkeit lässt sich auf verschiedenen Wegen herstellen. Einige Modelle sind intrinsisch interpretierbar – so die Ridge Regression, deren Koeffizienten direkt als Merkmalsgewichte lesbar sind. Komplexere Modelle erfordern nachgelagerte Verfahren. Für den Gradient-Boosting-Regressor wird die modellinterne Merkmalswichtigkeit (feature importance) herangezogen: Sie misst, wie stark ein Merkmal über alle Bäume hinweg zur Fehlerreduktion beiträgt, und liefert eine globale Rangfolge der wichtigsten Einflussgrößen, die sich mit den fachlichen Erwartungen und der explorativen Analyse (Kapitel 2) abgleichen lässt.

7.2 Globale Erklärbarkeit: Merkmalswichtigkeit des Gradient-Boosting-Modells

Abbildung 3 zeigt die nach Wichtigkeit geordneten Merkmale. Mit Abstand bedeutendstes Merkmal ist die Wohnfläche (livingSpace) mit rund 50 % der gesamten Merkmalswichtigkeit, was ihre dominierende Rolle als Preistreiber bestätigt. Es folgen die Nebenkosten (serviceCharge, ~11 %), das Bundesland (regio1, ~10 %), ein Preistrend-Merkmal (pricetrend, ~9 %) und die Postleitzahl (geo_plz, ~7 %); das Baujahr trägt ~5 % bei, die übrigen Merkmale jeweils wenig. Bemerkenswert ist, dass mehrere einflussreiche Merkmale keine physischen Wohnungseigenschaften, sondern Kosten- bzw. Inseratsmerkmale sind. Die in Abschnitt 2.3 aufgeworfene Frage lässt sich damit beantworten: serviceCharge und pricetrend gehören mit zusammen ~20 % zu den wichtigsten Größen, während picturecount (~1 %) kaum ins Gewicht fällt. Besonders die starke Bedeutung der Nebenkosten ist kritisch, da sie mit Größe und Ausstattung zusammenhängen und damit Information bereits enthaltener Merkmale duplizieren; pricetrend birgt zudem die Gefahr eines Zirkelschlusses, da es selbst aus Preisinformationen abgeleitet ist. Für eine produktive Anwendung wäre zu prüfen, ob auf solche Merkmale verzichtet werden sollte.




Abbildung 3 Merkmalswichtigkeit des Gradient-Boosting-Regressors.

7.3 Interpretierbarkeit der linearen Baseline

Anders als der Gradient-Boosting-Regressor ist die Ridge Regression unmittelbar interpretierbar: Da sie die Miete als gewichtete Summe der standardisierten Merkmale modelliert, geben Vorzeichen und Betrag der Koeffizienten Richtung und Stärke des Einflusses an, und die Standardisierung macht sie untereinander vergleichbar. Erwartungsgemäß liefert die Wohnfläche den größten positiven Beitrag. Die Aussagekraft ist allerdings doppelt eingeschränkt: Das Modell erfasst nur lineare, additive Zusammenhänge, und die label-kodierten kategorialen Merkmale werden als geordnete Zahlen interpretiert, obwohl ihnen keine Rangordnung zugrunde liegt – der Koeffizient von regio1 ist daher kaum sinnvoll deutbar. Die Koeffizienten eignen sich somit gut für die stetigen, physischen Merkmale, sind bei kategorialen Größen jedoch nur mit Vorsicht zu interpretieren.

7.4 Grenzen der Erklärbarkeit und Ausblick

Die Ansätze liefern ein konsistentes Bild, weisen aber Grenzen auf. Die Merkmalswichtigkeit gibt nur die Stärke, nicht die Richtung des Einflusses an. Zudem bevorzugen impuritätsbasierte Maße Merkmale mit vielen Ausprägungen systematisch, hier vor allem die Postleitzahl (geo_plz) mit mehreren Tausend Ausprägungen, deren Wichtigkeit dadurch überzeichnet sein kann. Beide Verfahren liefern überdies nur globale Erklärungen für das Gesamtmodell, keine lokalen Begründungen für einzelne Vorhersagen.

8. Räumliche Analyse

Bereits die explorative Datenanalyse und die Merkmalswichtigkeit haben die große Bedeutung der Lage gezeigt. Dieses Kapitel vertieft die räumliche Dimension der Mieten und stellt die dazu erstellten interaktiven Karten vor.

8.1 Bedeutung der räumlichen Merkmale

Der Datensatz enthält drei Merkmale unterschiedlicher räumlicher Auflösung: das Bundesland (regio1), den Landkreis bzw. die kreisfreie Stadt (regio2) und die Postleitzahl (geo_plz); insgesamt sind 16 Bundesländer und rund 2.660 Postleitzahlenbereiche vertreten. Gemeinsam tragen sie rund 19 % zur Merkmalswichtigkeit des Gradient-Boosting-Modells bei und bilden nach der Wohnfläche die zweitwichtigste Merkmalsgruppe. Wie ausgeprägt die regionalen Unterschiede sind, zeigt Abbildung 4: Die durchschnittliche Nettokaltmiete reicht von rund 376 € in der günstigsten bis zu rund 1.208 € in der teuersten Region (Spanne ~832 € bzw. über 200 %). Die Datenmenge ist regional sehr ungleich verteilt – einige Regionen sind mit Tausenden Inseraten vertreten, andere nur mit wenigen, deren Durchschnittsmieten entsprechend unsicher sind und nicht überinterpretiert werden sollten.




Abbildung 4 Durchschnittliche Mieten und Preisspannen nach Region.

8.2 Interaktive Karten (Leaflet / OpenStreetMap)

Zur anschaulichen Darstellung wurden zwei interaktive Karten auf Basis von OpenStreetMap erstellt und als eigenständige HTML-Dateien gespeichert; die zuvor numerisch kodierten Regionen wurden dafür wieder ihren Bundeslandnamen zugeordnet und an deren geografischen Mittelpunkten platziert. Die erste Karte (`interactive_rental_map.html`) stellt die durchschnittliche Miete je Bundesland farbcodiert von Grün (günstig) bis Rot (teuer) dar; per Klick werden Kennzahlen wie Durchschnittsmiete, Inseratszähl, Streuung, Minimum/Maximum sowie durchschnittliche Wohnfläche und Zimmerzahl eingeblendet. Die zweite Karte (`prediction_accuracy_map.html`) ergänzt dies um eine räumliche Betrachtung der Vorhersagegüte und macht sichtbar, in welchen Regionen das Modell verlässlicher und in welchen es mit größeren Abweichungen vorhersagt – aufschlussreich vor allem im Zusammenhang mit der ungleichen Datenverteilung.

9. Unsicherheitsanalyse

Bisher wurde die Güte anhand aggregierter Fehlermaße beurteilt. Für die Praxis ist jedoch ebenso wichtig, wie verlässlich eine einzelne Vorhersage ist. Eine reine Punktschätzung – „die Miete beträgt 800 €“ – vermittelt eine Scheingenaugkeit. Dieses Kapitel ergänzt die Punktvorhersagen daher um Vorhersageintervalle und untersucht, wie verlässlich diese kalibriert sind.

9.1 Motivation

Jede Vorhersage ist mit Unsicherheit behaftet, die aus der begrenzten Datengrundlage, nicht erfassten Einflussgrößen und der Streuung des Mietmarkts resultiert. Eine Punktschätzung lässt offen, wie groß diese Unsicherheit im Einzelfall ist. Vorhersageintervalle ordnen der Schätzung einen Vertrauensbereich zu: Ein 90%-Intervall ist so definiert, dass die tatsächliche Miete in etwa 90 % der Fälle darin liegen sollte. Für die Anwendung – Preisfindung durch Vermieter, Budgetplanung durch Mieter – ist dies wertvoll, da es eine realistische Risikoabschätzung erlaubt. Die Analyse erfolgt für die beiden leistungsfähigsten Modelle, den Gradient-Boosting-Regressor und das neuronale Netz.

9.2 Methodik

Verwendet wird ein residuenbasiertes Verfahren unter der Annahme näherungsweise normalverteilter Fehler. Aus den Residuen (Differenz zwischen tatsächlicher und vorhergesagter Miete) wird die Standardabweichung berechnet und mit dem Quantil der Standardnormalverteilung multipliziert (für 90 %: Faktor 1,645). Das Intervall ergibt sich als vorhergesagte Miete $\pm$ (Faktor $\times$ Standardabweichung der Residuen). Daraus folgt eine für alle Vorhersagen konstante Intervallbreite. Die Qualität wird über die empirische Abdeckung (coverage) geprüft – den Anteil der Testbeobachtungen, deren Miete im Intervall liegt; eine Abdeckung nahe 90 % spricht für gut kalibrierte Intervalle.

9.3 Ergebnisse

Der Gradient-Boosting-Regressor erreicht eine Abdeckung von 87,0 % bei einer mittleren Intervallbreite von rund 370 €, das neuronale Netz 86,4 % bei deutlich breiteren ~479 €. Beide liegen nahe am Ziel von 90 %, unterschreiten es aber leicht. Der Gradient-Boosting-Regressor erreicht dieselbe Abdeckung mit deutlich schmalere Intervallen – ein Ergebnis seiner geringeren Residuenstreuung. Konkret liegt für eine vorhergesagte Miete von 800 € die tatsächliche Miete mit rund 90 % Wahrscheinlichkeit zwischen etwa 687 € und 913 €. Die Residuen des Modells stützen die Plausibilität: Der mittlere Fehler liegt mit ~22 € nahe null, die Verteilung ist annähernd symmetrisch. Abbildung 5 zeigt die nach tatsächlicher Miete sortierten Testbeobachtungen mit Vorhersagen und 90%-Intervallen. Die leichte Unterschreitung des Zielwerts erklärt sich aus den vereinfachenden Annahmen: Konstante Intervallbreiten bilden die beobachtete Heteroskedastizität nur unzureichend ab, sodass die Intervalle im unteren Preissegment tendenziell zu breit, im oberen zu schmal ausfallen. Eine Verfeinerung durch preisabhängige Intervallbreiten wird in Kapitel 11 aufgegriffen.




Abbildung 5 90%-Vorhersageintervalle für Gradient Boosting und neuronales Netz.

10. Kritische Diskussion

Die Ergebnisse zeigen, dass sich Mietpreise aus Inseratsdaten mit beachtlicher Genauigkeit vorhersagen lassen. Eine seriöse Einordnung erfordert jedoch eine kritische Auseinandersetzung mit den Grenzen der Daten, Methoden und Werkzeuge.

10.1 Begrenzte Datenmenge und zeitliche Abdeckung

Aus Laufzeitgründen wurde nur ein Ausschnitt von 50.000 Inseraten verwendet, der zudem durch Einlesen der ersten Datensätze statt einer Zufallsstichprobe gebildet wurde – bei vorsortiertem Ausgangsdatensatz ist daher eine Verzerrung möglich. Schwerer wiegt die begrenzte zeitliche Abdeckung: Training stammt aus 2018–2019, Validierung und Test aus 2020, im Wesentlichen einer einzelnen Erhebung (Februar 2020). Die Zeitmerkmale weisen im Testzeitraum kaum Variation auf, sodass sich weder saisonale Effekte noch langfristige Trends belegen lassen und eine echte zeitliche Generalisierungsfähigkeit nicht nachweisbar ist.

10.2 Vereinfachte räumliche Darstellung

Die räumliche Information wurde nur vereinfacht abgebildet. Das Label-Encoding der Regionen erzeugt eine künstliche Rangordnung, die vor allem die Ridge Regression fehlinterpretiert; bei der Postleitzahl mit mehreren Tausend Ausprägungen begünstigt es zudem eine Überzeichnung der Merkmalswichtigkeit (vgl. Kapitel 7). Hinzu kommt die sehr ungleiche regionale Datenverteilung, und die Karten verorten die Regionen vereinfachend an ihren Mittelpunkten, ohne Fläche oder innerregionale Heterogenität abzubilden.

10.3 Fehlende externe Einflussgrößen

Die Modelle nutzen ausschließlich die in den Inseraten enthaltenen Merkmale. Wichtige Preisfaktoren fehlen – makroökonomische Größen wie Zinsniveau, Inflation oder Arbeitsmarktlage ebenso wie kleinräumige Standortfaktoren wie Zentrumsnähe, ÖPNV-Anbindung oder soziales Umfeld. Diese nicht erfasste Information äußert sich in den verbleibenden Vorhersagefehlern.

10.4 Datenqualität

Da es sich um Angebotsmieten handelt, können die Daten systematisch vom realen Mietniveau abweichen. Zudem mussten fehlende Werte imputiert werden, was die Verteilung leicht glättet. Besonders kritisch sind einige der einflussreichsten Merkmale: Die Nebenkosten (serviceCharge) hängen eng mit Größe und Ausstattung zusammen und duplizieren damit Information, während pricetrend selbst aus Preisinformationen abgeleitet ist und die Gefahr eines Zirkelschlusses birgt. Eine Schätzung allein auf objektiv beschreibenden Eigenschaften müsste auf solche Merkmale verzichten.

10.5 Softwaretechnische Aspekte

Die modular aufgebaute Pipeline erleichtert Nachvollziehbarkeit und Erweiterbarkeit, und feste Zufalls-Startwerte sichern die Reproduzierbarkeit. Methodisch bestehen jedoch Einschränkungen: Die Hyperparameter wurden manuell statt systematisch optimiert, eine Kreuzvalidierung wurde nicht durchgeführt, und die Unsicherheits-schätzung beruht auf vereinfachenden Annahmen (konstante Intervallbreiten).

11. Verbesserungsmöglichkeiten und Ausblick

Aus den Einschränkungen ergeben sich Ansatzpunkte für künftige Arbeiten. Auf Datenseite wären ein größerer, zeitlich breiter gestreuter Ausschnitt – idealerweise eine Zufallsstichprobe über mehrere Jahre – sowie die Einbindung externer Quellen (makroökonomische Indikatoren, kleinräumige Standortmerkmale) wünschenswert; Ersteres würde überhaupt erst eine belastbare Modellierung saisonaler und langfristiger Trends erlauben. Auf Modellierungsebene bietet sich vor allem eine veränderte Kodierung der kategorialen Merkmale an: Ein One-Hot- oder Target-Encoding würde die künstliche Rangordnung des Label-Encodings vermeiden und besonders die lineare Baseline verbessern. Ergänzend erscheinen ein erweitertes Feature Engineering (Gebäudealter, Interaktionsmerkmale, Log-Transformation der Zielvariable), eine systematische Hyperparameter-Optimierung mit Kreuzvalidierung sowie Ensembles oder regionalspezifische Teilmodelle vielversprechend. Im Bereich der Erklärbarkeit würden modellagnostische Verfahren wie SHAP oder LIME die Analyse vertiefen, da sie auch die Richtung des Merkmalseinflusses und Erklärungen für einzelne Vorhersagen liefern. Die Unsicherheitsschätzung ließe sich durch preisabhängige, die Heteroskedastizität berücksichtigende Intervallbreiten verbessern, etwa über Quantils Regression oder konforme Vorhersage (conformal prediction). In der Summe könnten diese Maßnahmen Vorhersagegüte, Transparenz und Verlässlichkeit weiter steigern.

12. Fazit

Im Rahmen dieser Arbeit wurde ein Machine-Learning-System zur Vorhersage der monatlichen Nettokaltmiete von Wohnungen in Deutschland entwickelt und vergleichend bewertet. Auf Basis von rund 49.000 bereinigten ImmoScout24-Inseraten wurden drei Modellklassen – Ridge Regression als interpretierbare Baseline, Gradient-Boosting-Regressor und neuronales Netz – auf einem einheitlichen Satz von 25 Merkmalen trainiert und anhand mehrerer Fehlermaße verglichen; ergänzt wurde dies um eine Analyse der Preistreiber, der räumlichen Unterschiede und der Vorhersageunsicherheit.

Die eingangs formulierten Ziele wurden erreicht: Es wurde eine funktionsfähige Vorhersage-Pipeline aufgebaut, drei Modellklassen vergleichend bewertet und die wichtigsten Preistreiber transparent gemacht. Das beste Modell, der Gradient-Boosting-Regressor, erreicht auf dem Testdatensatz einen MAE von rund 90 € und ein R^2 von etwa 0,87 und übertrifft damit das neuronale Netz und die lineare Baseline deutlich – wie für strukturierte, gemischt numerisch-kategoriale Daten zu erwarten. Die Merkmalswichtigkeit bestätigt die Wohnfläche als wichtigsten Preistreiber, gefolgt von der Lage und einzelnen Kosten- und Inserats Merkmalen; die Vorhersageintervalle erwiesen sich mit einer Abdeckung von rund 87 % als annähernd gut kalibriert.

Zugleich unterliegt die Arbeit den dargelegten Einschränkungen, insbesondere der schmalen zeitlichen Datenbasis, der vereinfachten Kodierung der räumlichen Merkmale und dem Verzicht auf eine systematische Modelloptimierung. Sie versteht sich daher als methodische Untersuchung im akademischen Rahmen. Die aufgezeigten Erweiterungen bieten einen klaren Ausgangspunkt, um Vorhersagegüte und praktische Verwendbarkeit künftig weiter zu steigern.